Objetivo

Comparar un recuperador léxico (TF-IDF + similitud coseno) con uno de semántica latente (LSA mediante TruncatedSVD con k=4) sobre un corpus de 10 documentos y 6 consultas con un documento relevante cada una. Se miden Hit@1, Hit@3 y MRR, se identifican las consultas donde cada método falla (relevante fuera del top 3) y se discute qué aportaría un recuperador denso.

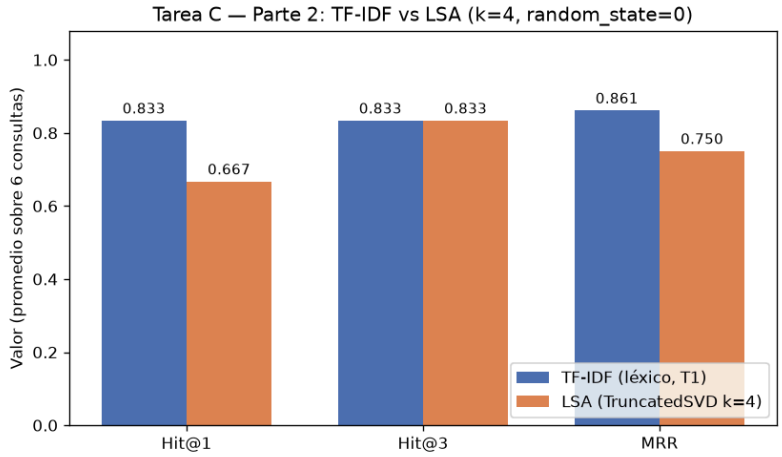
Método

- **Corpus y juicios:** 10 documentos (d01–d10); consultas q1–q6 con relevante único (q1→d04, q2→d03, q3→d08, q4→d05, q5→d09, q6→d02).
- **TF-IDF:** `TfidfVectorizer` de scikit-learn con parámetros por defecto, ajustado sobre los 10 documentos (las consultas solo se transforman); vocabulario de 105 términos; ranking por similitud coseno; desempate por orden estable de id.
- **LSA:** `TruncatedSVD(n_components=4, random_state=0)` sobre la misma matriz TF-IDF; consultas proyectadas con `transform`; coseno en el espacio latente de 4 dimensiones.
- **Métricas:** Hit@1, Hit@3 y MRR sobre las 6 consultas; fallo = relevante en posición ≥ 4. Análisis de términos compartidos con la tokenización por defecto del vectorizador.

Resultados

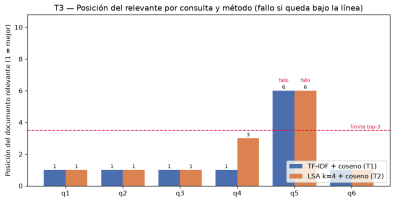
Tabla comparativa (Parte 2):

Método	Hit@1	Hit@3	MRR
TF-IDF + coseno	0.8333	0.8333	0.8611
LSA (k=4) + coseno	0.6667	0.8333	0.75
Δ (LSA – TF-IDF)	-0.1667	0.0	-0.1111



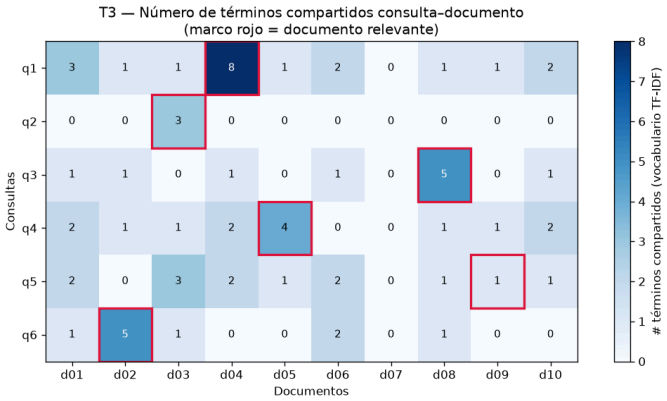
Rank del relevante por consulta (Parte 3):

Consulta	Relevante	Rank TF-IDF	Rank LSA	Fallo top-3
q1	d04	1	1	ninguno
q2	d03	1	1	ninguno
q3	d08	1	1	ninguno
q4	d05	1	3	ninguno
q5	d09	6	6	**ambos**
q6	d02	1	1	ninguno



LSA retiene 0.3953 de la varianza total (componentes: 0.0342, 0.1266, 0.1160, 0.1186).

Análisis del único fallo (q5, ambos métodos): la consulta comparte con d09 un solo término, "la" (df=6, idf=1.4520); siete palabras de la consulta están fuera de vocabulario (determinista, elegir, hace, más, palabra, sea, siguiente). En TF-IDF, d09 queda 6.º con similitud 0.0790, superado por d03 (0.3107), que comparte los términos raros "al" y "modelo" (idf 2.7047 cada uno), por d06 ("el", "qué") y por d04 ("la", "que"). En LSA, d09 también queda 6.º (0.4999), tras d04 (0.9427) y d01 (0.8066). Además, LSA degrada q4: d05 cae del puesto 1 al 3 (0.8984), superado por d01 (0.9220) y d10 (0.9206).



Discusión

TF-IDF coloca el relevante en el puesto 1 en 5 de 6 consultas: las coincidencias léxicas exactas con términos raros (alto idf) bastan en un corpus técnico mínimo. LSA no mejora: con k=4 solo conserva 0.3953 de la varianza y la proyección suaviza las diferencias entre documentos muy cortos, lo que cuesta 0.1667 de Hit@1 (q4 pasa de rank 1 a 3) y 0.1111 de MRR, sin cambio en Hit@3 (0.8333). Con solo 10 documentos no hay co-ocurrencias suficientes para que las dimensiones latentes capturen sinonimia útil.

El fallo compartido en q5 es un hueco léxico: las palabras distintivas de la consulta no aparecen en ningún documento y el único término compartido con d09 es "la", con df=6 y escaso poder discriminativo. Los documentos que superan a d09 lo hacen por términos raros pero semánticamente irrelevantes ("al", "modelo" en d03), un problema de matching literal que ni el idf ni la proyección latente corrigen.

Un recuperador denso entrenado resolvería q5 mejor porque sus embeddings, aprendidos sobre corpus grandes, codifican paráfrasis: "más determinista al elegir la siguiente palabra" quedaría cerca de "valores bajos concentran la probabilidad" aunque no compartan ningún término, exactamente el hueco que TF-IDF y LSA (ajustado solo sobre 10 documentos) no pueden cerrar. Sus costos frente a TF-IDF son: requerir un modelo preentrenado (memoria y cómputo), mayor latencia por consulta, reindexar todo el corpus con el encoder, perder interpretabilidad (no hay pesos por término que inspeccionar) y asumir riesgo de desajuste de dominio; TF-IDF sigue siendo ligero, determinista y explicable.